1. OBJETIVOS

1.1. OBJETIVO GENERAL

- Desarrollar y validar una red neuronal tipo Perceptrón Multicapa (MLP) entrenada con el método de Levenberg–Marquardt para aproximar la cinemática inversa de un manipulador robótico de 3 grados de libertad (3GDL), de modo que sea capaz de seguir trayectorias continuas y discretas en posición (X, Y) y orientación (φ) dentro de su espacio de trabajo.

1.2. OBJETIVOS ESPECÍFICOS

- Generar el conjunto de datos de entrenamiento mediante barrido de los ángulos articulares ($\theta_1, \theta_2, \theta_3$) y cálculo de la cinemática directa para obtener las coordenadas X; Y; φ
- Ajustar parámetros de entrenamiento Levenberg–Marquardt (μ inicial, μ_inc, μ_dec) y aplicar regularización L_2 para garantizar convergencia y robustez
- Definir criterios de parada (error objetivo, gradiente mínimo, no mejora del error) y medir el desempeño con MSE en los conjuntos de entrenamiento, validación y prueba.
- Probar la red en trayectorias continuas (circular y rectangular) con orientación senoidal.
- Probar la red en una trayectoria definida por puntos que forman la palabra “SITEM” con orientación senoidal.
- Comparar gráficamente las trayectorias deseadas vs. obtenidas y cuantificar su precisión mediante NRMSE en X, Y y φ.

2. DESARROLLO DE LA TAREA

2.1. GENERACIÓN DE DATOS

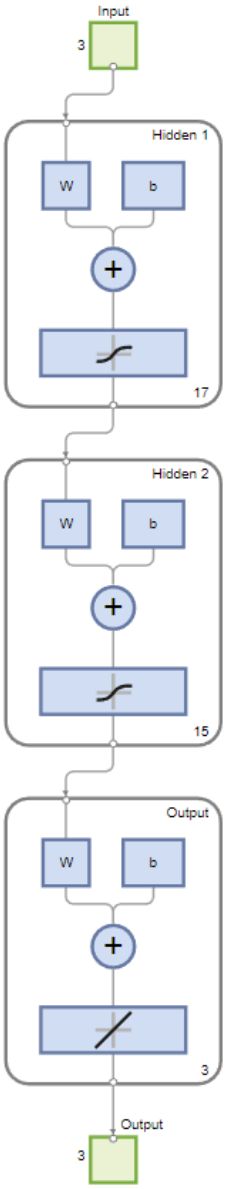
Nuestro robot es un robot de 3 GDL con articulaciones tipo revoluta, con una longitud de 1 m cada eslabón. Para entrenar la MLP, primero construimos un amplio conjunto de pares {cartesiano → articular}. Cada tripleta de ángulos se convierte en una posición (x,y,φ) mediante cinemática directa. Luego, restringimos el espacio de trabajo de nuestro robot con los siguientes parámetros: xmin=0.3; xmax=0.7; ymin=2.3; ymax=2.6. Para nuestra red neuronal tendremos 999 datos de entrada (x,y,φ) y 999 de salida (θ_1, θ_2 y θ_3)

2.2. ENTRENAMIENTO DE LA RED MLP

Empezamos cargando los datos previamente obtenidos, recordando que la entrada son las variables cartesianas y la salida son las variables articulares, obteniendo así dos matrices 3xN.

2.2.1 Arquitectura de la red neuronal

- Dos capas ocultas que permiten capturar no linealidades (15 y 12 neuronas)
- Ambas capas con función de activación sigmoide hiperbólica que produce salidas suaves entre –1 y 1, lo que ayuda a representar fenómenos complejos y continuos como trayectorias de robot.
- En la salida usamos una función de activación lineal que permite mantener una relación directa con las variables articulares
- Usamos el algoritmo de Levenberg-Marquardt para optimizar rápidamente sin fijar manualmente tasa de aprendizaje. Este método combina la eficiencia del método de Gauss-Newton con la robustez del descenso por gradiente, adaptando dinámicamente un parámetro de amortiguamiento μ. Cuando el error disminuye, el algoritmo se comporta como Gauss-Newton (rápido); si el error empeora, actúa como gradiente descendente (estable). Esta adaptación automática permite una convergencia más rápida y precisa.



2.2.2 Regularización de datos

Usamos regularización L_2 (también conocida como penalización Ridge), que es una técnica que busca mejorar la capacidad de generalización de una red neuronal evitando el sobreajuste. Lo fijamos en 0.2, lo cual significa que el 20% del cálculo del error total que la red intenta minimizar incluye una penalización proporcional al cuadrado de la magnitud de los pesos.

$$Error\ total = (1 - \alpha) \cdot MSE + \alpha \cdot \sum W^2$$

- MSE: Error cuadrático medio

- W: Pesos
- α : 0.2

2.2.3 Partición de datos

Dividimos los datos en entrenamiento/validación/prueba para asegurar evaluación imparcial según los porcentajes 80/10/10 (%) respectivamente.

2.2.4 Criterios de parada y monitoreo

Los criterios de parada controlan el momento en que el entrenamiento se considera finalizado:

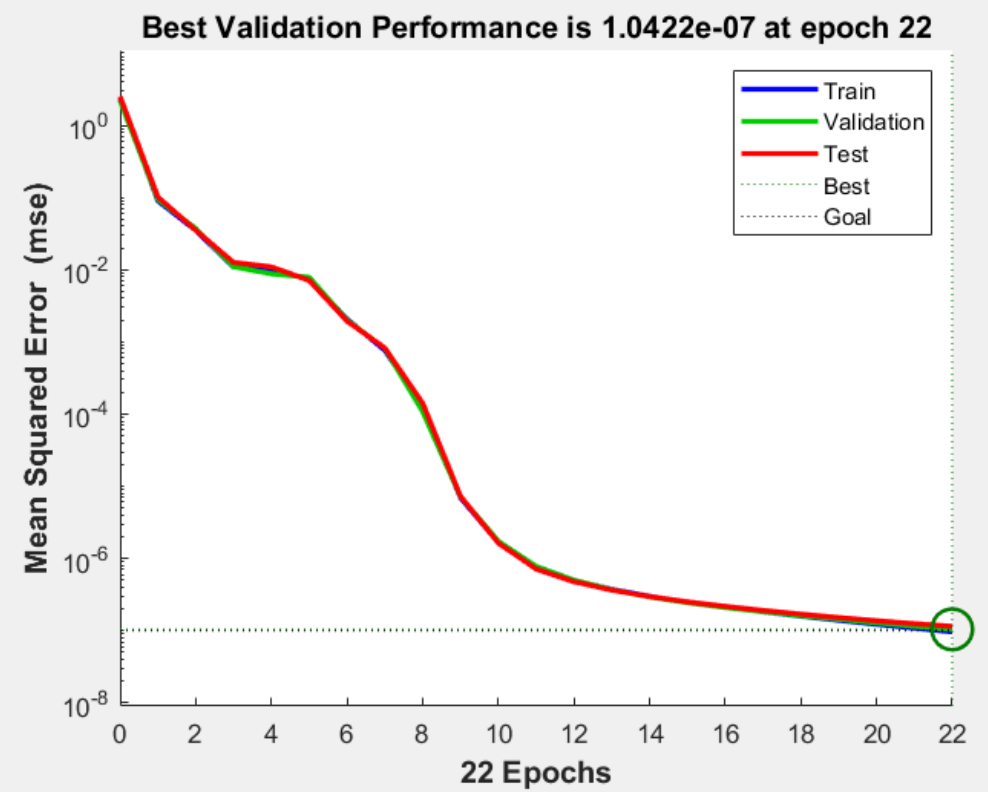
- Épocas: número máximo de iteraciones (50)
- Error objetivo: valor del error (MSE) que, si se alcanza, se detiene (10^{-7})
- Gradiente mínimo: si la mejora es tan pequeña que el gradiente cae por debajo de este valor, se asume convergencia (10^{-6})
- No mejora del error: número máximo de iteraciones consecutivas sin mejora en el error de validación (5)
- Time: tiempo límite (infinito en este caso)
- μ (mu): factor de ajuste del paso en la actualización de los pesos de la red neuronal durante el entrenamiento (μ inicial = 0.001)
- Factor de reducción: Si el error disminuye, μ se reduce a μ × 0.1 → se permite un ajuste más agresivo y rápido.
- Factor de incremento: Si el error aumenta, μ se incrementa a μ × 10 → se vuelve más conservador y evita sobresaltos.

2.3. RESULTADOS DEL ENTRENAMIENTO

- El entrenamiento se detuvo después de 22 épocas, mucho antes del límite máximo (50), lo cual indica una convergencia rápida.

- Se alcanzó un error cuadrático medio (MSE) de $9.64 \cdot 10^{-8}$, menor que el objetivo definido (10^{-7}), razón por la cual se detuvo automáticamente el entrenamiento.
- El gradiente disminuyó desde 5.74 hasta $9.08 \cdot 10^{-4}$, acercándose al mínimo objetivo en que se asumía convergencia(1e-6), reflejando que la red ajustó correctamente sus pesos.
- El valor de μ pasó de 0.001 a 10^{-7}, indicando que el algoritmo se desplazó progresivamente hacia el método Gauss-Newton conforme mejoraba la solución.
- No se realizaron paradas tempranas por validación, lo cual muestra que no hubo sobreajuste durante las iteraciones.

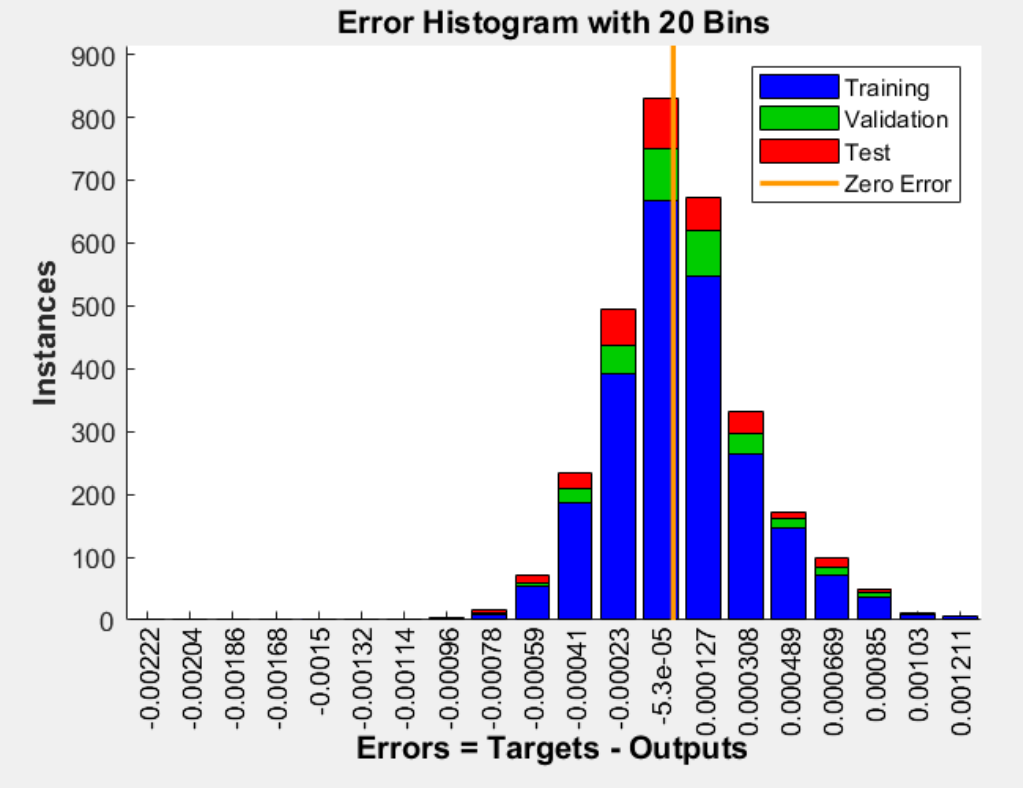
2.3.1 Rendimiento



Como podemos ver a medida que avanza el entrenamiento, todas las curvas (entrenamiento, validación, prueba) muestran una tendencia descendente, lo que indica que el modelo está disminuyendo el error con cada época. Además, la mejor precisión en validación se alcanza en

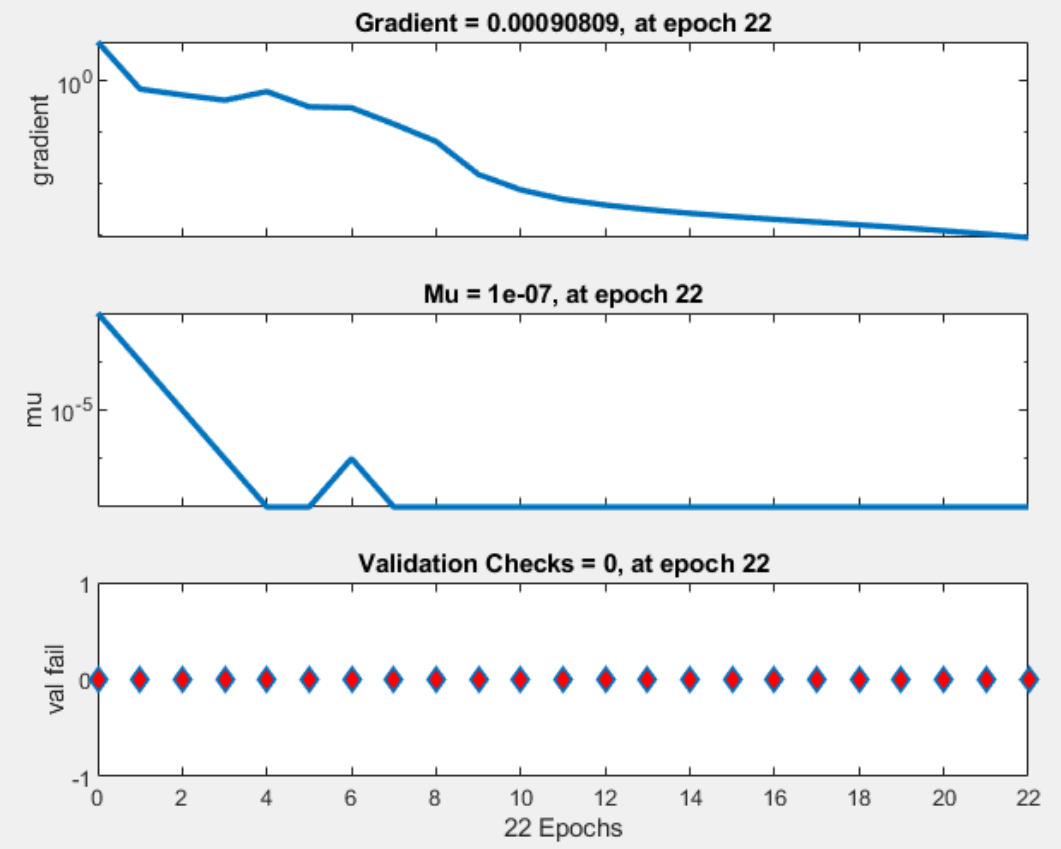
la época 22 con un MSE de 1.0422×10^{-7}, lo que sugiere una excelente capacidad de generalización. Y el modelo al parecer evita el sobreajuste, ya que el error de prueba también se mantiene bajo y estable.

2.3.2 Histograma de error



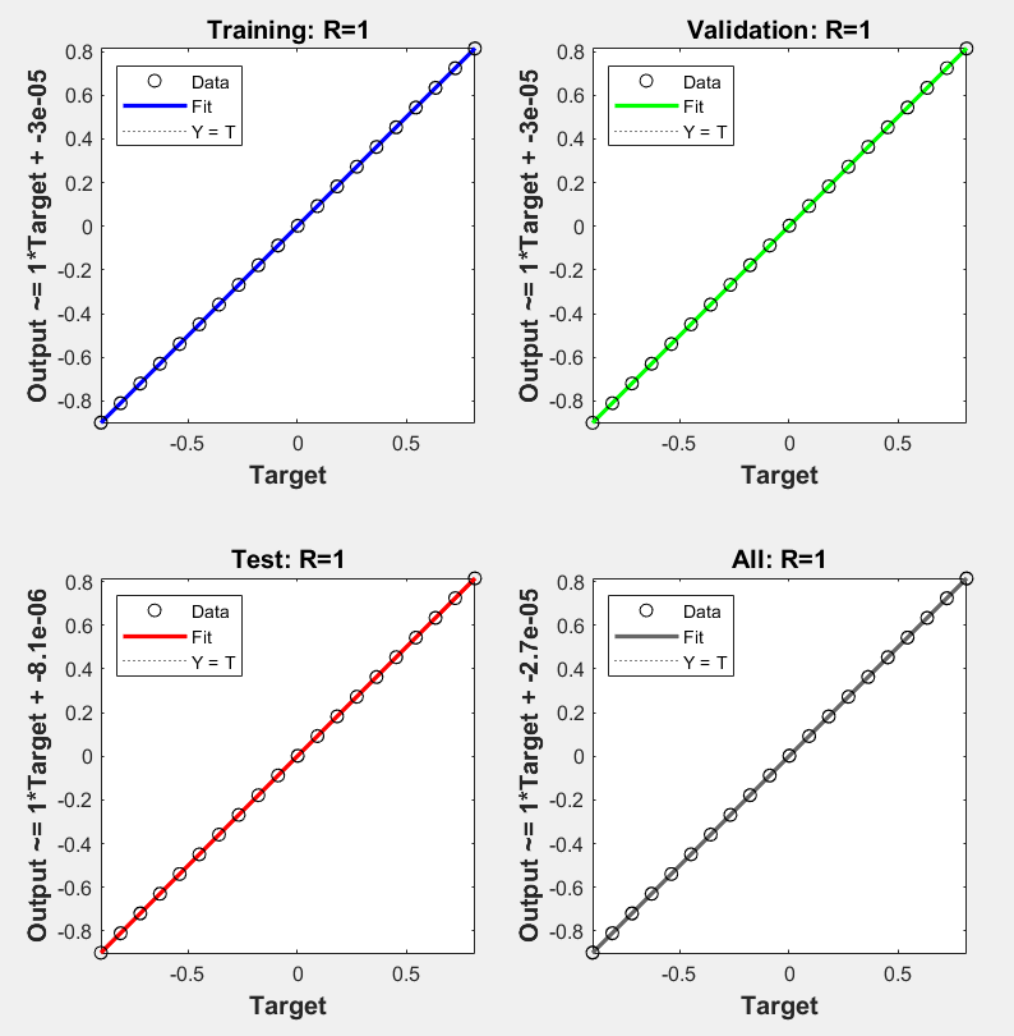
Podemos observar que la mayoría de los errores se concentran muy cerca de cero, con un pico en torno a -5.3×10^{-5}. Además, al no aparecer agrupamientos en valores extremos, nos indica ausencia de outliers relevantes. La simetría alrededor de cero nos revela también que el modelo no genera un sesgo sistémico hacia predicciones siempre por encima o por debajo del valor real.

2.3.3 Evolución de parámetros



- La reducción sostenida de la gradiente indica que el algoritmo está encontrando direcciones de menor error y afinando los pesos de manera estable.
- El descenso de Mu sugiere que el ajuste por Gauss–Newton se vuelve cada vez más confiable, mejorando la convergencia, a pesar del pico en la 6ta época.
- El validation Check permanece en 0 durante todo el entrenamiento, lo que significa que en cada época se obtuvo una mejora (o al menos no empeoró) en el conjunto de validación.

2.3.4 Regresión



Los diagramas de dispersión muestran que las predicciones del modelo se alinean perfectamente con los valores reales en todos los subconjuntos de datos. Cada panel - Entrenamiento (azul), Validación (verde), Prueba (rojo) y Conjunto completo (gris) - presenta:

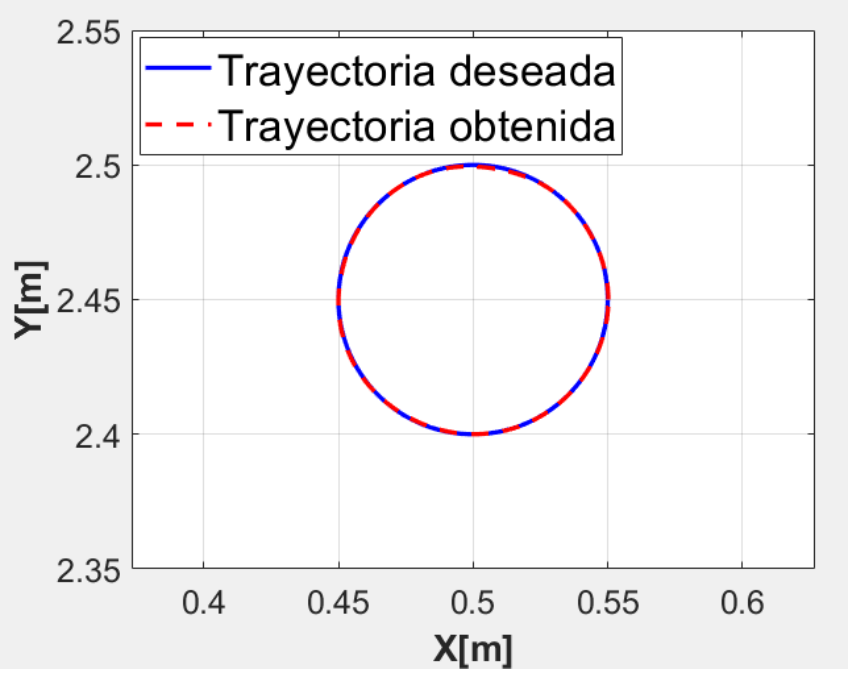
- Una recta de mejor ajuste con pendiente aproximadamente 1 e intercepto casi cero.
- Un coeficiente de correlación R igual a 1

En todos los casos, el modelo es prácticamente perfecto, reproduciendo de forma idéntica la relación entre entrada y salida.

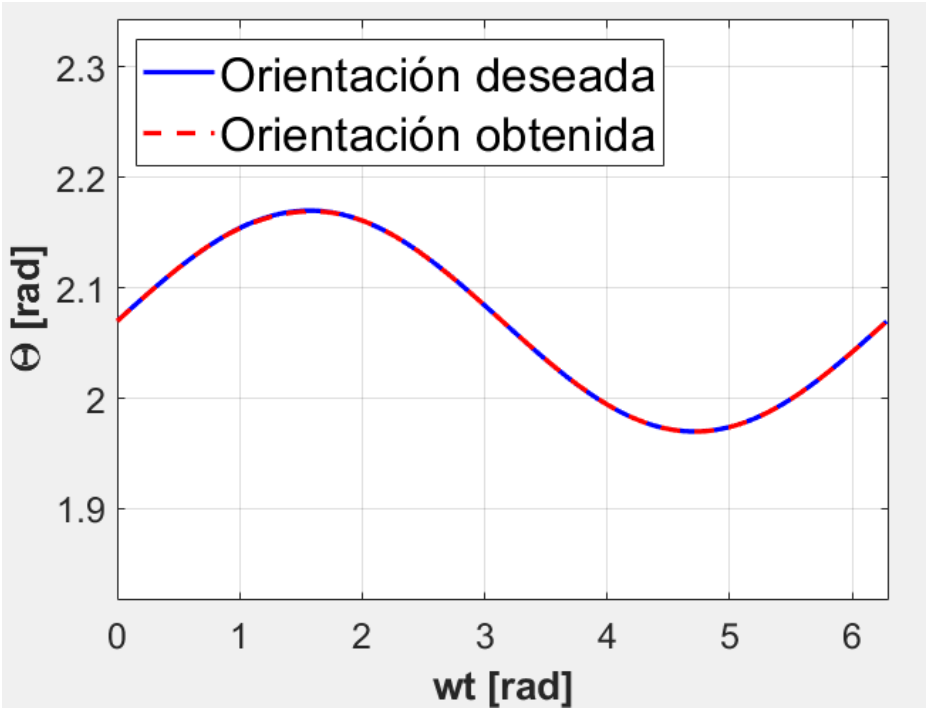
2.4. VALIDACIÓN CON TRAYECTORIAS

2.4.1 Trayectoria circular con orientación senoidal

Se genera un pequeño círculo centrado en la zona de interés con orientación variable. La entrada normalizada pasa por la MLP, se recuperan los ángulos y se calcula la posición resultante.



La orientación senoidal sobre la trayectoria circular implica que el ángulo φ sigue una oscilación sinusoidal alrededor de un punto central, permitiendo evaluar la respuesta ante cambios de dirección combinados con variación periódica del ángulo.

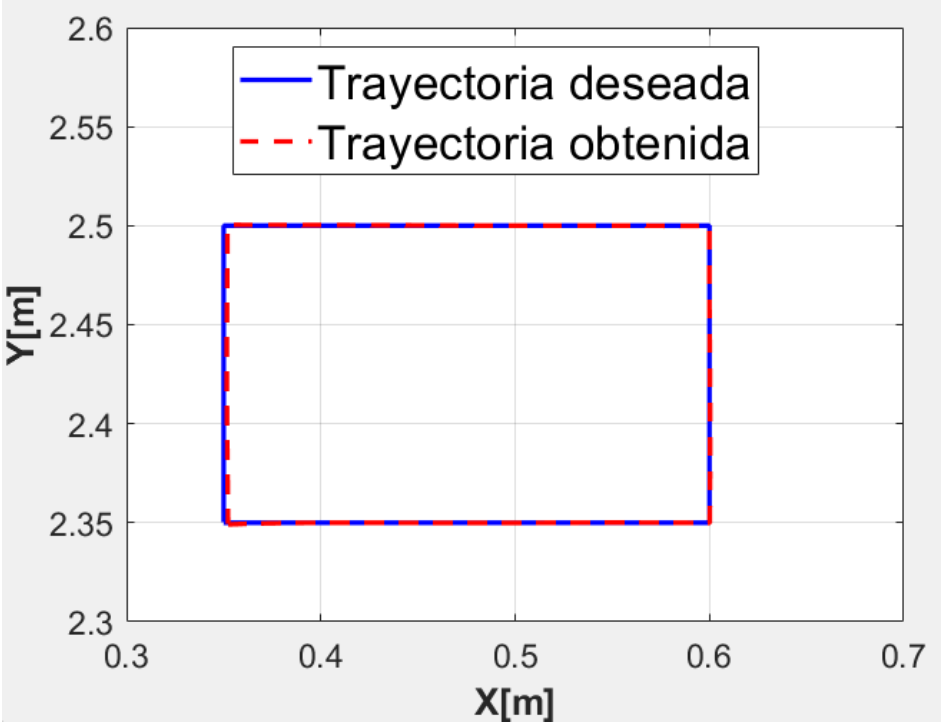


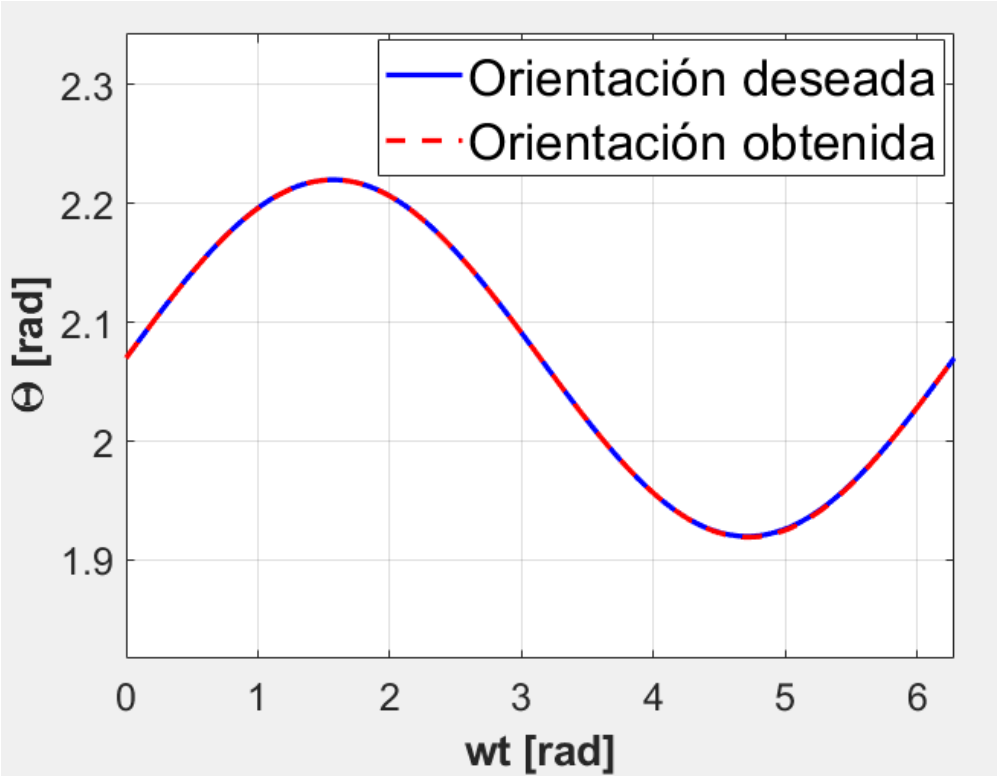
Cuantificamos la precisión a partir de la Raiz del Error Cuadrático Medio Normalizado (NRMSE)

- NRMSE en X: 0.8044%
- NRMSE en Y: 0.6456%
- NRMSE en Orientación: 0.3414%

2.4.2 Trayectoria rectangular con orientación senoidal

Usando los mismos mecanismos que con la trayectoria circular obtenemos las siguientes gráficas de posición y orientación.



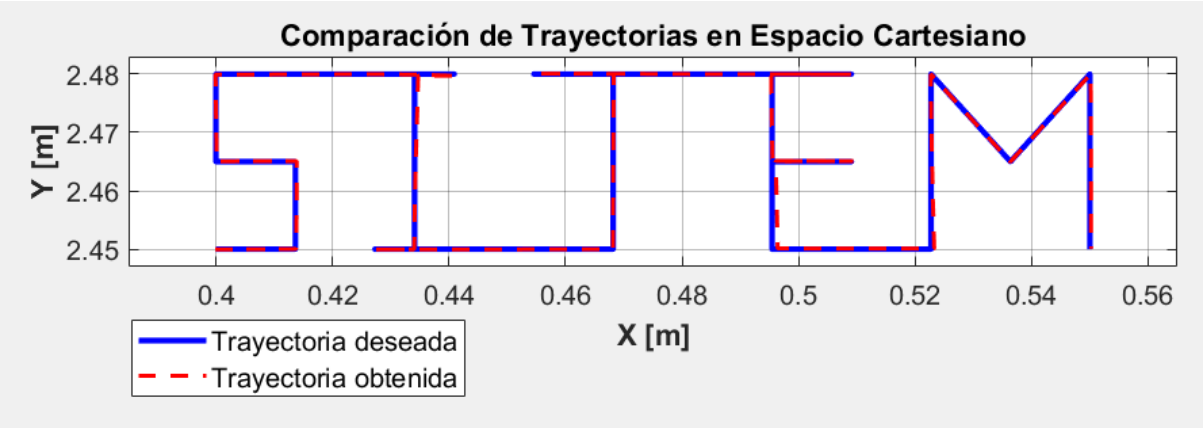


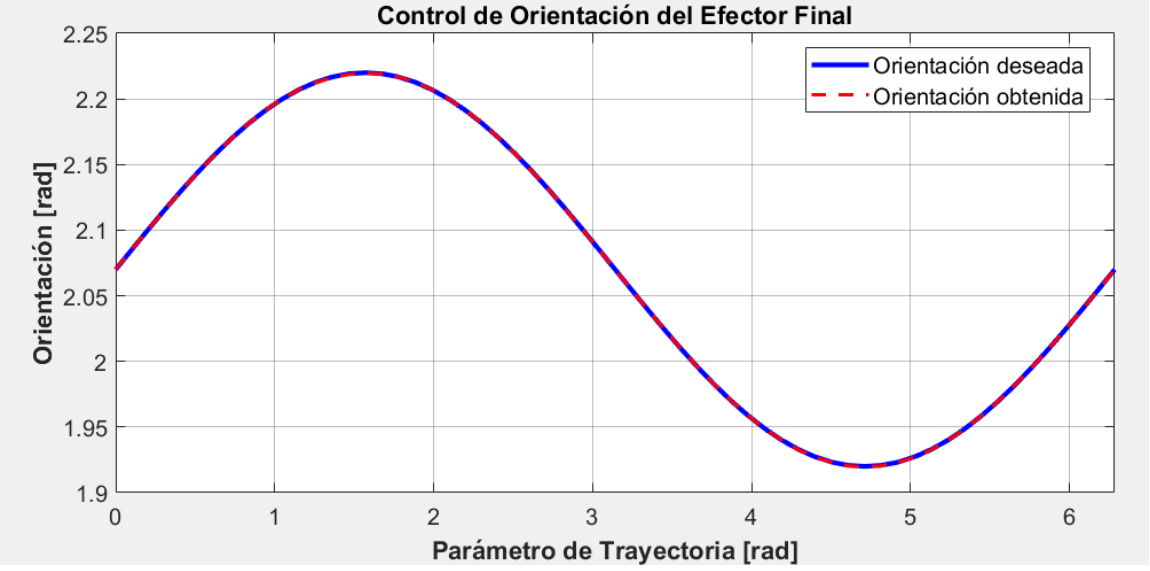
Cuantificamos la precisión a partir de la Raiz del Error Cuadrático Medio Normalizado (NRMSE)

- NRMSE en X: 1.0292%
- NRMSE en Y: 0.3457%
- NRMSE en Orientación: 0.3223%

2.4.2 Trayectoria definida por puntos en el plano con orientación senoidal

Primero definimos manualmente un conjunto de puntos para formar la trayectoria, luego escalamos al espacio de trabajo del robot. Finalmente aplicamos el mismo procedimiento visto con las anteriores 2 trayectorias.





Cuantificamos la precisión a partir de la Raiz del Error Cuadrático Medio Normalizado (NRMSE)

- NRMSE en X: 0.6685%
- NRMSE en Y: 0.6800%
- NRMSE en Orientación: 0.1629%

3. **Conclusiones**

- Se generó exitosamente un conjunto de datos que cubre de forma densa y uniforme el espacio articular del robot, permitiendo construir una base robusta de correspondencias entre configuraciones articulares y posiciones cartesianas.
- Los valores seleccionados para el algoritmo Levenberg–Marquardt lograron un equilibrio entre velocidad de convergencia y estabilidad del aprendizaje, mientras que la regularización L_2 permitió evitar el sobreajuste, favoreciendo una buena generalización.
- Los criterios de parada definidos permitieron finalizar el entrenamiento en un punto óptimo, evitando tanto el sobreentrenamiento como una convergencia prematura, como lo evidencian los bajos valores de MSE en los tres subconjuntos.
- La red neuronal mostró una respuesta precisa y fluida frente a trayectorias continuas con orientación variable, reproduciendo con fidelidad tanto el trazo espacial como los cambios suaves en la orientación, lo que demuestra su capacidad de generalización.
- A pesar de tratarse de una trayectoria no continua, la red logró mantener alta fidelidad en la trayectoria espacial y en la orientación, lo que evidencia su capacidad de extrapolación parcial.
- Las comparaciones visuales y métricas mostraron una alta coincidencia entre la trayectoria deseada y la obtenida, con errores normalizados (NRMSE) bajos en X y Y, y un desempeño excelente en φ.

4. **REFERENCIAS BIBLIOGRÁFICAS**

- Siciliano,B.,Sciavicco,L.,Villani,L.,& Oriolo,G.(2010).Robotics: Modelling,Planning and Control.Springer Science & Business Media.

5. ANEXOS

Archivos y video:

https://drive.google.com/drive/folders/1BR6H3L92EEWaa9r9VGymjstTJcsFjrvM?usp=sharing